Desafio Técnico: Auditoria de Risco Cadastral e Compliance B2B com Dados da RFB

Avaliação prática de competências em **Engenharia de Dados (ETL)**, **Modelagem Dimensional**, **Storytelling em BI (Power BI & Python)** e **Análise de Risco Corporativo**.

1 Cenário de Negócio & Contexto do Projeto

Contexto Corporativo: Em grandes organizações empresariais, a gestão de suprimentos e compras corporativas (Procurement / Supply Chain) contrata centenas de empresas parceiras e prestadores de serviços, movimentando centenas de milhões de reais anualmente. Para assegurar governança, conformidade fiscal (KYC - *Know Your Partner*) e mitigar riscos de fraudes fiscais, a gerência de dados precisa auditar periodicamente todos os fornecedores homologados.

O Desafio: Há suspeitas de que parceiros comerciais ativos nos cadastros internos estejam com o **CNPJ baixado, inapto ou nulo** na Receita Federal do Brasil (RFB), ou prestando serviços com **CNAE incompatível** com a atividade contratada. O seu papel é construir a solução ponta a ponta: **extrair, validar, modelar e construir visualizações executivas e operacionais** em **Power BI** e em **Python**.

2 Dados Fornecidos & O Desafio de Data Sourcing (RFB)

⚠️ **Parte Integrante do Desafio (Obtenção Autônoma dos Dados):** A empresa fornece **exclusivamente** a base interna de fornecedores homologados. Os dados cadastrais oficiais e a tabela de CNAEs da Receita Federal do Brasil (RFB) **NÃO serão fornecidos prontos**. Cabe ao candidato pesquisar, descobrir e implementar a forma mais eficiente de consultar ou baixar esses dados públicos (seja via portal de Dados Abertos da RFB, dumps oficiais ou APIs públicas com estratégia de cache e resiliência).

ORIGEM DOS DADOS	DISPONIBILIZAÇÃO	VOLUMETRIA	PRINCIPAIS CAMPOS & DETALHES
Base de Fornecedores Homologados `base_fornecedores_homologados`	Fornecido no Teste	1.500 registros	`ID_FORNECEDOR`, `CNPJ`, `RAZAO_SOCIAL_INFORMADA`, `CATEGORIA_FORNECIMENTO`, `VALOR_CONTRATADO_ANUAL`, `STATUS_HOMOLOGACAO`, `DATA_ULTIMO_PAGAMENTO`.
Dados Públicos de CNPJ da RFB *(Estabelecimentos & Situação)*	Obtenção pelo Candidato	Dados Oficiais RFB	O candidato deve obter: `situacao_cadastral` (Ativa, Baixada, Inapta, Suspensa), `data_situacao`, `cnae_fiscal_principal`, `cnae_secundaria`, `uf` e `municipio`.
Dimensão CNAE Oficial *(Tabela de Atividades Econômicas)*	Obtenção pelo Candidato	Tabela Oficial IBGE/RFB	O candidato deve obter a descrição textual correspondente aos códigos de CNAE para classificar a aderência das atividades no BI.

3 Entregáveis Obrigatórios

1. Estratégia de Sourcing & ETL

Scripts em **Python** (ou **SQL / Shell**) documentados demonstrando como os dados da RFB foram coletados, higienizados, validados pelo Módulo 11 e cruzados com a carteira.

2. Dois Dashboards de BI

A) Power BI (.pbix): Modelagem Star Schema e medidas DAX explícitas.
B) Web App Python: Aplicação interativa reativa (Streamlit, Dash ou Plotly).

3. README & Envio dos Entregáveis

Arquivo `README.md` justificando a fonte e método escolhidos para obter os dados da RFB, premissas de negócio e instruções. Os entregáveis devem ser encaminhados para o e-mail combinado com a GEP.

💡 **Envio dos Entregáveis & Avaliação:** Encaminhe a solução compactada (ou link do repositório) para o **e-mail combinado com a equipe de Gestão de Pessoas (GEP)** dentro do prazo estipulado. O uso de ferramentas modernas e assistentes de código é permitido, contanto que o candidato compreenda e saiba sustentar tecnicamente todas as decisões adotadas no projeto.

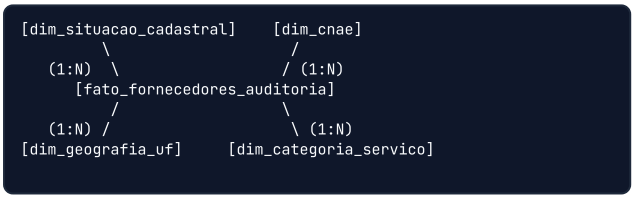
4 Etapa 1: Ingestão, Qualidade e Higienização de Dados (ETL)

Atenção: A base bruta contém armadilhas reais de qualidade de dados. Soluções ingênuas costumam falhar nestes 5 pontos críticos. O candidato será avaliado pelo rigor no tratamento de cada uma:

DESAFIO / ARMADILHA	COMPORTAMENTO ESPERADO DO CANDIDATO	IMPACTO SE NÃO FOR TRATADO
Truncamento de Zeros à Esquerda	Padronizar todos os CNPJs para **14 dígitos exatos (VARCHAR)** com `.zfill(14)` ou `LPAD()` antes de qualquer busca.	CNPJs iniciados por `0` (ex: `02.421...`) perdem dígitos no Excel e não casam no JOIN com a RFB.
Validação do Módulo 11 da RFB	Implementar a fórmula matemática oficial dos **dois dígitos verificadores** do CNPJ e rejeitar sequências inválidas (ex: `00000000000000`).	Carregar registros com erros de digitação como se fossem válidos, distorcendo auditorias.
Conflitos de Encodings	Garantir leitura e escrita corretas em **UTF-8** sem corrupção de caracteres especiais oriundos de arquivos **CP1252 (Windows-1252)**.	Textos como *"São Paulo"* viram *"So Paulo"*, quebrando filtros e pesquisas textuais.
Cardinalidade de CNAEs Secundários	A coluna de CNAEs secundários possui múltiplos códigos separados por vírgula. Criar uma tabela associativa (Bridge) ou normalização sem duplicar a Fato.	Fazer `explode()` ingênuo sem chave substituta duplica as linhas e multiplica os valores financeiros no BI.
Identificação Matriz x Filial	Extrair o **CNPJ Raiz** (primeiros 8 dígitos) e classificar se o parceiro comercial é **Matriz (`0001`)** ou **Filial (demais ordens)**.	Incapacidade de analisar grupos econômicos que concentram múltiplos contratos em filiais diferentes.

5 Etapa 2: Modelagem Dimensional & Regras de Negócio

Esquema Estrela Recomendado (Star Schema)



*Evitar modelos com tabela única desnormalizada ("tabelão"). Modelar as chaves de relacionamento com integridade referencial.

Classificação de Risco Operacional

CLASSIFICAÇÃO	REGRA DE NEGÓCIO (RFB X CADASTRO INTERNO)
Regular	Homologado e **ATIVA (02)** na RFB com CNAE condizente com a categoria contratada.
Atenção	Homologado e ATIVA na RFB, porém **CNAE desconexo** com o escopo do serviço prestado.
Crítico	Homologado, porém **BAIXADA (08), INAPTA (04), NULA (01) ou CNPJ Inválido** na RFB.

6 Exemplo de Consulta SQL Analítica Esperada

```sql
-- Exemplo de agregação de auditoria por Situação Cadastral e Exposição Financeira
SELECT
    COALESCE(s.situacao_descricao, 'NÃO ENCONTRADO / INVÁLIDO') AS situacao_rfb,
    COUNT(f.id_fornecedor) AS total_fornecedores,
    ROUND(COUNT(f.id_fornecedor) * 100.0 / SUM(COUNT(f.id_fornecedor)) OVER(), 2) AS perc_base,
    ROUND(SUM(f.valor_contratado_anual), 2) AS valor_total_exposto,
    SUM(CASE WHEN f.cnpj_valido_digito = 'NAO' THEN 1 ELSE 0 END) AS qtd_cnpj_invalido
FROM fato_fornecedores_auditoria f
LEFT JOIN dim_situacao_cadastral s ON f.id_situacao_rfb = s.id_situacao
GROUP BY 1 ORDER BY valor_total_exposto DESC;
```

7 Requisitos Obrigatórios para os Dois Ambientes de BI

Entregável A: Power BI (.pbix)

- **Modelagem Star Schema:** Relacionamentos `1:N` unidirecionais com integridade referencial.
- **Medidas DAX Explícitas:** Tabela dedicada `_Medidas`. Proibido uso de colunas calculadas desnecessárias ou medidas implícitas.
- **Fórmulas DAX Esperadas:** `[Total Fornecedores]`, `[% Regularidade]`, `[Valor Risco Crítico]`, `[Qtd Grupos Econômicos]`.
- **Design System:** Uso elegante da paleta institucional (Roxo `#6330BF`, Neutros e cores semânticas de risco).

Entregável B: Web App Python (Streamlit / Dash)

- **Aplicação Reativa:** Rodar localmente via comando `streamlit run app.py` (ou equivalente em Dash/Plotly).
- **Barra Lateral de Filtros:** Filtros múltiplos por UF, Categoria de Serviço, Situação Cadastral e Nível de Risco.
- **Performance com Cache:** Utilizar cache (`@st.cache_data`) para carregamento instantâneo da base.
- **Exportação:** Botão interativo para baixar a lista filtrada de inconsistências em `.csv`.

8 Arquitetura de Telas Recomendadas para os Dashboards

Visão 1: Painel Executivo & Exposição Financeira — Estratégica

Objetivo: Fornecer um panorama imediato para a liderança sobre a integridade cadastral e risco financeiro.
• **KPIs em Destaque:** Total de Fornecedores, Taxa de Regularidade na RFB (%), Valor Total Contratado e Volume Financeiro em Risco Crítico.
• **Gráfico de Composição (Rosca/Barra):** Distribuição percentual das situações cadastrais (Ativa, Baixada, Inapta, Suspensa).
• **Matriz de Risco:** Cruzamento entre o Status de Homologação interno vs Situação na Receita Federal.

Visão 2: Auditoria de CNAE & Compatibilidade — Compliance

Objetivo: Identificar empresas fornecedoras com desvio de finalidade econômica ou CNAE desconexo.
• **Termômetro de Aderência:** % de fornecedores cujo CNAE Principal é compatível com a Categoria de Fornecimento.
• **Top 10 CNAEs Primários:** Volume de fornecedores e valor contratado por descrição econômica oficial.
• **Inspeção de CNAEs Secundários:** Nuvem ou gráfico de barras dos ramos secundários mais comuns informados pelos parceiros.

Visão 3: Distribuição Geográfica & Grupos Econômicos — Mercado

Objetivo: Mapear a concentração de mercado e estrutura corporativa dos fornecedores.
• **Mapa / Gráfico de Barras por UF:** Concentração de fornecedores por estado da federação, colorido por taxa de irregularidade.
• **Análise de Grupo Econômico (CNPJ Raiz):** Ranking dos maiores grupos fornecedores (empresas com maior volume de filiais contratadas).
• **Proporção Matriz vs Filiais:** Volume de compras faturadas na sede vs filiais operacionais.

Visão 4: Central de Ação & Bloqueio Operacional — Operacional

Objetivo: Permitir que o time de contas a pagar atue diretamente nas anomalias encontradas.
• **Grid Detalhado com Busca Rápida:** Pesquisa por Razão Social, CNPJ ou ID de Fornecedor.
• **Flags de Anomalia Visíveis:** Tags coloridas indicando: *"CNPJ Inválido"*, *"Empresa Baixada"*, *"Divergência Cadastral"*.
• **Ação de Exportação:** Botão direto para exportar a listagem de pendências para bloqueio preventivo de pagamentos no ERP.

💡 **Dica de Storytelling & Visualização:** Mais do que montar telas funcionais, avaliaremos se o dashboard guia o usuário do problema macro (Visão Executiva de Exposição) até a ação pontual no fornecedor com irregularidade (Central de Ação). Concluído o desenvolvimento, encaminhe os entregáveis para o **e-mail combinado com a GEP**.